UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Industrial

PROYECTO INTEGRADOR: REGRESIÓN
CASO 1 – EQUIPO 5

ESTIMACIÓN DE LA DEGRADACIÓN DEL COMPRESOR DE UNA TURBINA A GAS NAVAL A PARTIR DE SENSORES DE OPERACIÓN

Integrantes del Equipo 5

Claudio Andrés Pérez Lagos
Daniela Sofía Sepúlveda Serrano
Ariel Felipe Garrido Armijo
Benjamín Fernando Sanchez Vargas
Elías Andrés Rita Rodríguez

PROFESOR: Luis Rojo-González, Ph.D.
ASIGNATURA: Estadística Aplicada

SANTIAGO – CHILE
2026

Resumen ejecutivo

Se estima la pérdida de rendimiento del compresor de una turbina a gas naval (y, de 0 a 5 puntos porcentuales) con la velocidad y 11 sensores en régimen estacionario, para priorizar inspecciones. Como los datos son una grilla simulada, la validación aleatoria era engañosa: el modelo se eligió con validación anidada que deja fuera una velocidad completa. Elastic-net logró un RMSE de 1,243 frente a 1,476 de la media global (mejora de 15,8 %; IC 95 % de la diferencia: [−0,440; −0,027]) y de 1,007 y 1,053 en los dos test. Su precisión individual es limitada: se recomienda como filtro de inspección entre 3 y 27 nudos, previa validación con datos reales.

1 Problema, datos y disponibilidad temporal

Decisión. El planificador de mantenimiento decide cuándo inspeccionar el compresor, cuya degradación no se mide en operación. Sobreestimarla adelanta intervenciones innecesarias; subestimarla prolonga la operación con un compresor de menor rendimiento.

Unidad, respuesta y población. Cada fila es un estado estacionario definido por la velocidad (3 a 27 nudos, 9 niveles), la degradación del compresor (k_{Mc}, 51 niveles) y la de la turbina (k_{Mt}, 26 niveles): $9 \times 51 \times 26 = 11.934$ filas, una grilla completa. La respuesta $y = 100(1 - k_{Mc})$ toma 51 valores equiespaciados entre 0 y 5. La población son los estados estacionarios de esta planta en ese rango de velocidades.

Fuente y licencia. *Condition Based Maintenance of Naval Propulsion Plants* (Coraddu et al.), UCI Machine Learning Repository, licencia CC BY 4.0 [1]. Son datos simulados, sin período calendario.

Faltantes y disponibilidad. No hay faltantes ni filas duplicadas (verificado en el script); la receta imputa la mediana del fold solo como salvaguarda. Se estima el estado *actual*, sin horizonte de pronóstico, con 12 mediciones simultáneas: la velocidad y 11 sensores (Anexo A). Se excluyen T1 y P1 (constantes), Tp (idéntica a Ts), la posición de palanca (correlación 0,9999 con la velocidad) y k_{Mt}, que no se observa en operación y sería fuga de información. La grilla uniforme no refleja la frecuencia real de cada nivel de degradación, y sus filas vecinas comparten condiciones de operación.

2 Relaciones e inferencia

Con el entrenamiento (8.486 filas) se ajustó `lm`: $y = \beta\,\mathrm{T2} + \alpha_v + \varepsilon$, con una indicadora por velocidad. A igual velocidad, +10 K en la temperatura de salida del compresor (T2; equivale a +10 °C) se asocia a +1,753 puntos de pérdida (IC 95 % de `confint`: [1,708; 1,798]; con errores estándar robustos a heterocedasticidad, [1,694; 1,812]; $p < 0{,}001$). **Relevancia:** una desviación estándar de T2 dentro de cada velocidad equivale a 0,940 puntos, el 64 % de la desviación estándar de y (1,476); T2 explica el 40,6 % de la variación que deja sin explicar la velocidad (proporción de variación explicada, como η^2). **Supuestos:** ambos intervalos casi coinciden, por lo que la conclusión no depende de suponer varianza constante entre velocidades. La independencia no se cumple: la grilla es simulada y no es una muestra aleatoria, así que el valor-p casi no informa (significancia no es relevancia) y el intervalo se lee como descriptivo. La relación es asociativa: T2 refleja la degradación, no la causa.

3 Validación y preparación

Partición. Se reservaron dos test: la velocidad de 15 nudos completa (1.326 filas; velocidad no vista) y un 20 % aleatorio del resto (2.122 filas; interpolación). El entrenamiento tiene 8.486 filas en 8 velocidades (semilla 20261016).

Por qué se agrupa por velocidad. Solo con el entrenamiento, una validación cruzada aleatoria de 5 particiones elige splines naturales con RMSE 0,011; dejando una velocidad completa fuera, esa misma configuración da 18,520 (Elastic-net: 0,699 frente a 2,396). La validación aleatoria mezcla filas del mismo régimen entre ajuste y evaluación y no representa el uso futuro, que es estimar en una condición de operación nueva. Por eso la unidad de partición es la velocidad: se deja fuera una velocidad completa (partición por grupos, LOSO).

Validación anidada y preparación. En el nivel externo se deja fuera cada una de las 8 velocidades; dentro de cada una, una validación con las 7 restantes elige los hiperparámetros con la regla de un error estándar (1-SE, análoga a `lambda.1se`). Imputación, eliminación de predictores de varianza cero, estandarización y nudos de los splines son pasos de una receta que se estima solo con la parte de ajuste de cada fold. Las particiones son comunes a todos los modelos y las semillas son fijas.

Sin fuga. k_{Mt} queda fuera de los predictores; el script verifica que ninguna fila se comparta entre conjuntos y que la velocidad de 15 nudos no esté en el entrenamiento. Ninguna decisión (partición, modelo, hiperparámetros, intervalos, umbral) usa los test. Ambos test se examinaron en un análisis exploratorio previo: su evaluación es confirmatoria y no totalmente independiente, y la evidencia principal es la validación anidada.

4 Modelos

- **Baseline:** media de y en la parte de ajuste. La media por velocidad no aporta, porque k_{Mc} es ortogonal a la velocidad en la grilla.

- **OLS (lineal):** colinealidad extrema entre sensores (VIF máximo de 49.907 con todo el entrenamiento y de 130.360 entre particiones) y error inestable (RMSE de 21,042 a 27 nudos), lo que motiva la regularización.
- **Ridge, Lasso y Elastic-net:** $\lambda \in \{10^{-4}, \ldots, 1\}$ (10 valores) y, en Elastic-net, $\alpha \in \{0{,}25; 0{,}5; 0{,}75\}$, elegidos por 1-SE.
- **Flexibles:** splines naturales en 7 sensores (GTT, GGn, T48, T2, P2, m_f y TIC) con grados de libertad en {2, 3, 4, 6, 8}, elegidos por 1-SE; y un GAM con $s(\cdot)$ (splines cúbicos de regresión) en esos sensores y efecto lineal en el resto; `mgcv` controla la suavidad penalizando la curvatura, estimada solo con la parte de ajuste de cada partición.
- **Árbol y ensembles**, elegidos por 1-SE: árbol ($cp \in \{10^{-6}, \ldots, 10^{-3}\}$, profundidad $\in \{6, 10, 15\}$); Random Forest (500 árboles, $m_{try} \in \{3, 6, 10\}$, tamaño mínimo de nodo $\in \{2, 5, 20\}$); XGBoost (300 u 800 rondas, $\eta \in \{0{,}05; 0{,}15\}$, profundidad $\in \{4, 8\}$). En las 8 particiones se eligió la configuración más simple: árbol con $cp = 0{,}001$ y profundidad 6; RF con $m_{try} = 3$ y nodo mínimo 20; XGBoost con 300 rondas, $\eta = 0{,}05$ y profundidad 4.
- **Promedio Elastic-net + Ridge** (50/50), con los hiperparámetros 1-SE de cada partición. Se incorporó después de la selección.

Sistema final: Elastic-net con $\lambda = 0{,}0060$ y $\alpha = 0{,}5$, elegido por 1-SE con las 8 velocidades del entrenamiento, reajustado con las 8.486 filas y congelado antes de evaluar.

5 Comparación, test y subgrupos

Validación. Solo los modelos regularizados y su promedio mejoran al baseline (Tabla 1). Elastic-net lo hace en 7 de 8 velocidades: ΔRMSE pareado $= -0{,}233$ (IC 95 %, t con 7 g.l.: $[-0{,}440; -0{,}027]$); Ridge, $-0{,}223$ $[-0{,}421; -0{,}026]$; Lasso, $-0{,}142$ $[-0{,}319; 0{,}035]$, cuyo intervalo incluye el cero. Random Forest (+0,305 [0,066; 0,543]) y XGBoost (+0,302 $[-0{,}057; 0{,}660]$) son peores que el baseline en 8 y 7 de 8 velocidades. Los flexibles no generalizan a regímenes no vistos: los splines dan 0,468 a 0,945 entre 6 y 18 nudos, pero 4,518 a 3 y 11,521 a 27; el GAM, 0,060 a 0,332 entre 3 y 9 nudos y 125,074 a 27. Su complejidad no se justifica. El IC es aproximado: las particiones comparten velocidades de ajuste.

Entrenamiento frente a validación (Figura 1, derecha; $\alpha = 0{,}5$). Con el λ más chico, el RMSE de entrenamiento baja a 0,709 y el de validación sube a 2,021 (sobreajuste); con $\lambda \geq 0{,}129$ ambos igualan al baseline (subajuste). Con el λ elegido, la brecha se reduce a 0,170 (1,029 frente a 1,199) y los test (1,007 y 1,053) no superan al entrenamiento: el modelo no está sobreajustado. La brecha que queda refleja el costo de estimar en una velocidad no vista.

Test y subgrupos. El sistema congelado se evaluó una sola vez en los dos test (Tabla 2). En el subgrupo crítico ($y \geq 4$), el RMSE de validación de Elastic-net es 1,630, contra 2,020 del baseline; en test, 1,343 (aleatorio, 442 filas) y 1,060 (15 nudos, 286 filas), frente a 2,049 y 2,026. El árbol tiene menor error en ese subgrupo (1,343 en validación), pero peor error global (2,053). En test, el error es mayor en los extremos de degradación (15 nudos: 1,681 con $y < 1$ y 0,511 con $2 \leq y < 3$): el modelo acerca sus estimaciones a la media. Por régimen, el peor caso es el borde de 3 nudos (Figura 1).

Intervalos de predicción. El semiancho es el cuantil empírico de los 8.486 errores absolutos de validación del entrenamiento, sin usar los test. Al 90 %, el semiancho es ±1,943 puntos, la cobertura en test es de 96,3 % y 97,3 %, y el ancho medio, de 3,704 y 3,765 puntos: son conservadores y poco informativos frente al rango de 0 a 5. **Robustez:** con un ruido del 1 % de la desviación estándar en cada sensor, el RMSE de validación sube 0,42 % en promedio (máximo 0,82 %).

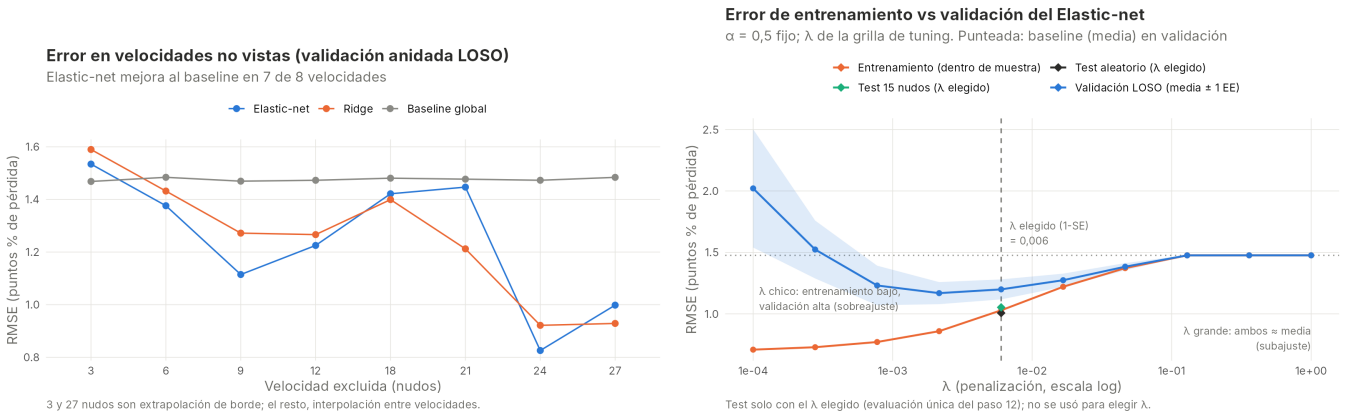


Figura 1: RMSE (puntos %). Izquierda: en cada velocidad excluida del ajuste (validación anidada); Elastic-net mejora al baseline salvo en el borde de 3 nudos (0,826 a 1,534). Derecha: entrenamiento frente a validación según λ, con el test solo en el λ elegido. Sustentan el rango de uso y el λ elegido.

6 Interpretación, límites y recomendación

Patrones predictivos, no causales. Coeficientes estandarizados (puntos por cada desviación estándar del sensor): T2 +8,12, presión de escape −4,53, P2 −3,36, Ts +1,93 y velocidad −1,87. Al reajustar en las 8 particiones, T2 varía entre 7,92 y 9,08, la presión de escape entre −5,09 y −3,26 y P2 entre −3,48 y −3,10; solo GGn cambia de signo. **Importancia por permutación** en cada velocidad excluida: permutar T2 aumenta el RMSE en 0,392 (en las 8 velocidades), la presión de escape en 0,122 y P2 en 0,052; el resto, menos de 0,02. **PDP e ICE** (Figura 2, izquierda): las curvas son rectas paralelas, como corresponde a un modelo lineal sin interacciones. Las predicciones fuera de 0 a 5 muestran que fijar un sensor sin mover los demás crea combinaciones que no existen en la planta.

Multicolinealidad y SHAP (Figuras 3 y 2, derecha). 65 de los 66 pares de predictores tienen $|r| \geq 0{,}9$ (dominado por la velocidad) y todos los VIF superan 10: por eso se regulariza y ningún coeficiente es un efecto aislado. En un modelo lineal, el SHAP de cada predictor es su coeficiente estandarizado por (valor − media); la suma reproduce la predicción respecto de la media (2,499 puntos; verificado en el script). Su aporte absoluto medio (T2 7,336; presión de escape 3,951; P2 2,986 puntos) sigue el orden de la permutación y supera el rango de y (0 a 5): los aportes de sensores correlacionados se compensan. Describen cómo el modelo combina sensores redundantes, no efectos de cada uno.

Límites. (i) Datos simulados, en régimen estacionario, sin ruido de medición. (ii) Validez solo entre 3 y 27 nudos: a 3 nudos no mejora al baseline (1,534 frente a 1,468) y la extrapolación no está validada. (iii) Los test no son totalmente independientes. (iv) El error individual es alto (RMSE ≈1 punto en una escala de 0 a 5).

Recomendación. Usar Elastic-net como filtro de inspección, no para fijar la fecha de una intervención: inspeccionar si la pérdida estimada es ≥2,5 puntos. Ese umbral se eligió solo con las predicciones de validación, como el más alto que detecta al menos el 90 % de los casos críticos ($y \geq 4$): en validación detecta el 90,3 %, con 36,4 % de falsas alarmas, y alerta el 48,1 % de los estados. En test detecta el 94,6 % y el 100 %, pero a 15 nudos las falsas alarmas suben a 65,3 % (alerta el 72,8 %). **Monitoreo (drift):** no usarlo si la velocidad o algún sensor sale del rango de entrenamiento; comparar cada estimación con el resultado de la inspección por régimen de velocidad, y recalibrar si la cobertura observada del intervalo al 90 % cae bajo su nivel nominal. Antes de operar, debe validarse con datos reales.

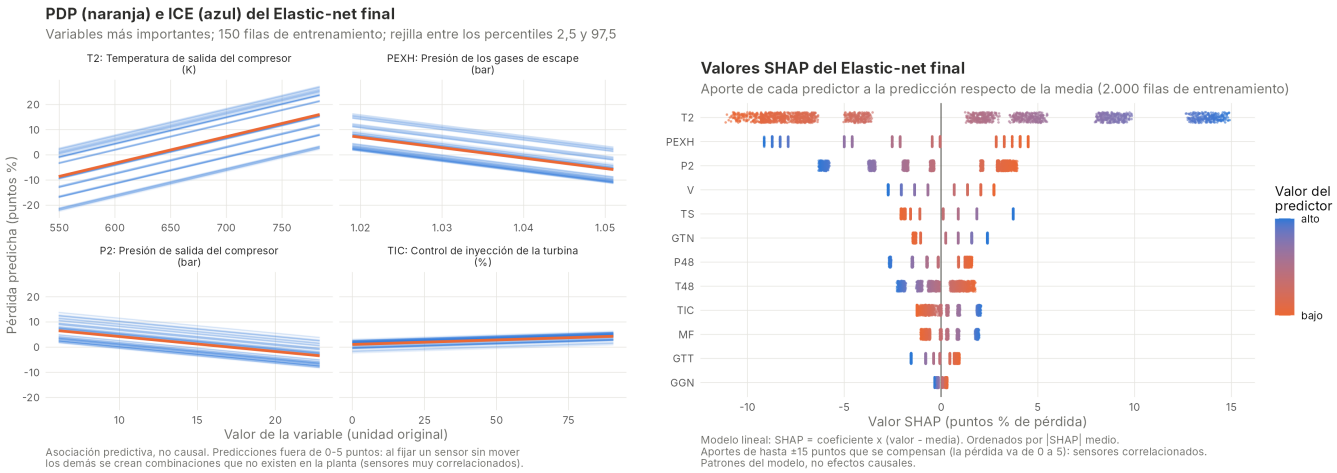


Figura 2: Interpretación del Elastic-net final con filas de entrenamiento. Izquierda: PDP e ICE de las 4 variables más importantes (150 filas). Derecha: valores SHAP (puntos %, 2.000 filas). Sustentan usar la estimación conjunta de los sensores, no razonar sobre un sensor aislado.

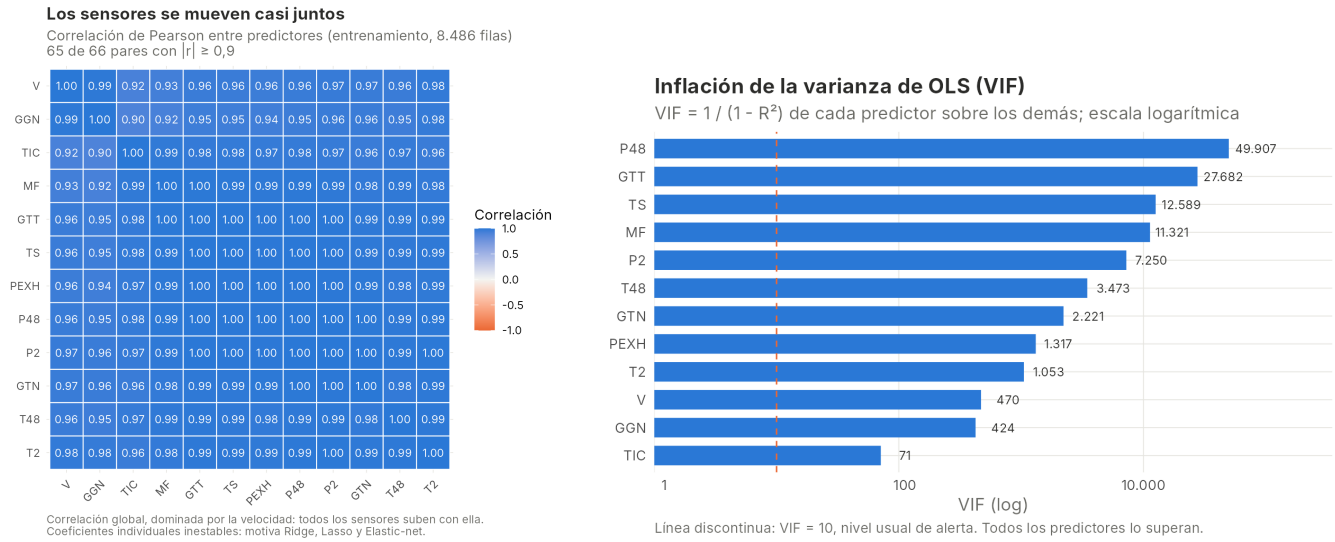


Figura 3: Multicolinealidad (entrenamiento). Izquierda: correlación entre predictores. Derecha: VIF de cada predictor en OLS (escala logarítmica). Sustentan reemplazar OLS por modelos regularizados.

7 Comparación y resultado final

El sistema final, Elastic-net, tiene el menor RMSE de validación anidada (1,243). Ridge (1,253) no difiere de él: $\Delta = -0{,}010$ $[-0{,}111;\ 0{,}091]$. El promedio con Ridge (1,225) mejora apenas 0,018 y se incorporó después de la selección; por eso se mantiene Elastic-net, sin reelegir con los test.

Tabla 1: Resultados de validación (promedio de las 8 velocidades excluidas del ajuste; RMSE $\pm$ desviación estándar entre velocidades; errores en puntos %). Sustenta la elección de la familia regularizada.

Modelo	Familia	RMSE	MAE	R^2	RMSE subgrupo ($y \geq 4$)	vs baseline
Baseline (media global)	—	1,476 $\pm$ 0,006	1,279	0,000	2,020	referencia
OLS[c]	Lineal	5,198 $\pm$ 6,715	5,068	−29,248	5,544	−252,1 %
Ridge[a]	Regularizado	1,253 $\pm$ 0,234	1,075	0,257	1,683	+15,1 %
Lasso[a]	Regularizado	1,334 $\pm$ 0,212	1,151	0,165	1,720	+9,6 %
Elastic-net[a] (final)	Regularizado	**1,243 $\pm$ 0,247**	1,081	0,266	1,630	+15,8 %
Splines naturales[a]	Flexible	2,736 $\pm$ 3,787	2,701	−8,130	3,056	−85,4 %
GAM[b]	Flexible	18,107 $\pm$ 43,389	18,085	−896,173	18,283	−1126,6 %
Árbol de regresión[a]	Árbol	2,053 $\pm$ 0,419	1,703	−1,003	1,343	−39,1 %
Random Forest[a]	Ensemble (bagging)	1,781 $\pm$ 0,286	1,502	−0,488	1,822	−20,6 %
XGBoost[a]	Ensemble (boosting)	1,778 $\pm$ 0,429	1,499	−0,524	1,873	−20,4 %
Promedio EN + Ridge[d]	Ensemble (averaging)	1,225 $\pm$ 0,233	1,047	0,289	1,656	+17,0 %

[a] Anidada (validación interna dejando una velocidad fuera, 1-SE). [b] Suavidad penalizada, estimada en cada partición. [c] Sin hiperparámetros. [d] Miembros con 1-SE interno; incorporado después de la selección. R^2: promedio de los R^2 por velocidad. vs baseline: reducción porcentual del RMSE (negativo = peor que la media).

Tabla 2: Sistema final (Elastic-net, $\lambda = 0{,}0060$, $\alpha = 0{,}5$), reportado una sola vez. Errores en puntos %; IC 95 % por bootstrap de filas, que ignora la dependencia de la grilla. Mejora: reducción porcentual del RMSE frente al baseline (media del entrenamiento). Sin R^2 ni mejora en entrenamiento: no son comparables con los de validación. Sustenta la magnitud de la mejora y la condición de uso.

Evaluación	RMSE [IC 95 %]	MAE	R^2	Mejora
Entrenamiento (dentro de muestra)	1,029	0,852	—	—
Validación anidada (8 velocidades)	1,243	1,081	0,266	15,8 %
Test aleatorio (2.122 filas)	1,007 [0,983; 1,034]	0,831	0,521	30,8 %
Test 15 nudos (1.326 filas)	1,053 [1,024; 1,080]	0,897	0,488	28,5 %

Referencias

[1] Coraddu, A., Oneto, L., Ghio, A., Savio, S., Anguita, D. y Figari, M. (2014). *Condition Based Maintenance of Naval Propulsion Plants* [Conjunto de datos]. UCI Machine Learning Repository. Licencia CC BY 4.0. `https://doi.org/10.24432/C5K31K`

[2] Rojo-González, L. (2026). *Estadística Aplicada* [Material de clases]. Departamento de Ingeniería Industrial, Universidad de Santiago de Chile.

A Diccionario de variables

Todas las variables se miden en el mismo instante, en régimen estacionario (ventana: instantánea, sin rezagos), y están disponibles al estimar, salvo k_{Mt}. Las temperaturas están en K: UCI las rotula en °C, pero T1 = 288 constante solo es físico en Kelvin.

Variable	Descripción	Tipo	Unidad	Rol y disponibilidad al estimar
y	Pérdida de rendimiento del compresor, $100(1-k_{Mc})$	Continua (51 niveles)	puntos %	Respuesta (no disponible: se estima)
v	Velocidad del buque	Continua (9 niveles)	nudos	Predictor (disponible)
GTT / GTn	Torque / revoluciones de la turbina a gas	Continuas	kN m / rpm	Predictores (disponibles)
GGn	Revoluciones del generador de gas	Continua	rpm	Predictor (disponible)
Ts	Torque de hélice (estribor)	Continua	kN	Predictor (disponible)
T48 / P48	Temperatura / presión de salida, turbina de alta presión	Continuas	K / bar	Predictores (disponibles)
T2 / P2	Temperatura / presión de salida del compresor	Continuas	K / bar	Predictores (disponibles)
Pexh	Presión de los gases de escape	Continua	bar	Predictor (disponible)
TIC / m_f	Control de inyección / flujo de combustible	Continuas	% / kg/s	Predictores (disponibles)
lp; Tp	Posición de palanca; torque de hélice (babor)	Continuas	—; kN	Excluidas: $\approx v$; = Ts
T1, P1	Temperatura y presión de entrada del compresor	Constantes	K; bar	Excluidas: sin variación
k_{Mt}	Coeficiente de degradación de la turbina	Continua (26 niveles)	—	Excluida: no observable al estimar

B Reproducibilidad y declaración de IA

Ejecución. Desde la carpeta raíz, en una sesión limpia de R: `source("codigo/00_main.R")`. Ejecuta los pasos 10 a 25, regenera tablas y figuras y registra configuración, `sessionInfo()`, versiones y tiempos (58,7 min en la ejecución registrada, Windows 11). Semilla global 20261016 (partición, folds y modelos; en cada partición externa, semilla + velocidad), semilla 20261031 para la simulación de ruido y un solo hilo. El paso 11 compara el ranking anidado con la referencia incluida (tolerancia 10^{-3}). Una ejecución independiente en Linux (R 4.3.3) reprodujo todas las tablas, salvo XGBoost en el tercer decimal (RMSE 1,776 frente a 1,778), que depende de la versión del paquete. Versiones: R 4.6.1, data.table 1.18.6.1, dplyr 1.2.1, tibble 3.3.1, tidyr 1.3.2, ggplot2 4.0.3, rlang 1.3.0, rsample 1.3.2, recipes 1.4.0, parsnip 1.6.1, workflows 1.3.0, tune 2.1.0, yardstick 1.4.0, dials 1.4.4, generics 0.1.4, glmnet 5.2, ranger 0.18.0, xgboost 3.2.1.1, rpart 4.1.27, sandwich 3.1.3 y mgcv 1.9.5. Origen de las cifras (paso): inferencia 10; validación anidada 11; test, subgrupo e hiperparámetros 12; ruido 15; intervalos y umbral 16; coeficientes 14 y 17; OLS y VIF 18; Tabla 1 y comparaciones pareadas 21; importancia y PDP/ICE 22; validación aleatoria 23; correlaciones y SHAP 24; entrenamiento frente a validación 25.

Declaración de IA. Se utilizó un asistente de IA (Claude, de Anthropic) para auditar el código, reorganizar el pipeline, ejecutarlo y apoyar la redacción. Su trabajo se verificó con las comprobaciones automáticas del script (partición, fuga y reproducibilidad). El equipo ejecutó el script completo en su computador (Windows 11, R 4.6.1; 58,7 min); las cifras de este informe se contrastaron con las tablas de esa ejecución.